03 · 总体架构设计

项	内容
文档 ID	TG-DOC-03
版本	v1.1（重构升级：CQRS / 多级缓存 / 事件总线 / OTel / 多品牌适配 / A2A）
编制日期	2026-10-26（首版 2026-10-25）
依据	TOGAF B/C/D / 4A / C4 / DDD / CQRS
状态	已评审，v1.1 重构已落地（对照 docs/43）

1. 架构概览（C4-L1 系统上下文）

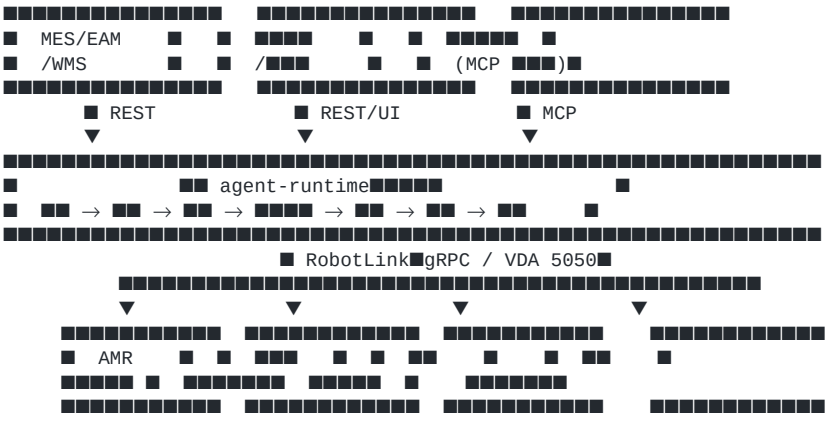

2. 具身智能体分层：大脑 / 小脑 / 脊髓

借鉴 2026 年 VLA 三代演进共识（端到端 VLA → 增强型 VLA → 类脑 VLA，如 NeuroVLA 的大脑-小脑-脊髓架构），本项目的工程映射：

层	职责	本项目实现	时延要求
大脑（认知）	意图理解、任务分解、调度决策、异常处置	agent-runtime（LLM 规划器 + 规则兜底）	秒级
小脑（技能）	具体动作技能执行（取放/搬运/读数）	具身技能（VLA 或规则，受治理）	百毫秒
脊髓（反射）	围栏、停机、急停	tiangong_core.safety（运行时层）	毫秒级

> 关键架构决策：脊髓层不依赖大脑。即使 LLM 挂了，围栏/停机/急停依然生效（对应 VLA 类脑架构的"碰撞反射 20ms"思想，用确定性代码实现）。

3. C4-L2 容器图

容器	技术	职责
agent-runtime	Python / Litestar / Granian	REST + MCP + A2A + 编排闭环
tiangong_core	纯 Python 包	领域核（分解/调度/安全/证据/技能/飞轮）

容器	技术	职责
repository	SQLite WAL（写主读从双连接）	作业单/任务/episode/技能/审计/安全区持久化（CQRS 读写分离）
multi-level cache	L1 进程内 TTL + L2 可插拔（Redis 接口预留）	热点读加速、前缀失效、命中率统计
event bus	Event + Transport 抽象（Memory 实现；Pulsar/Redis 预留）	领域事件发布/重放/统计
tracer	OTel GenAI SemConv 对齐（无 SDK 依赖）	Session > Trace > Span 三层可观测
robot-link-adapters	各厂商 adapter（gRPC）+ VDA 5050（MQTT）	协议适配（关差异）、健康探测、注册表
memory	工作记忆 / 情景记忆 / 技能记忆（Hermes 三层）	上下文与经验沉淀
episode-store	对象存储 / 消息队列（生产）	数据飞轮
审批流	钉钉/企业微信（外部）	人工令牌签发
运营看板	单文件 HTML（无第三方依赖）	机群遥测 / 任务板 / 安全区地图 / KPI

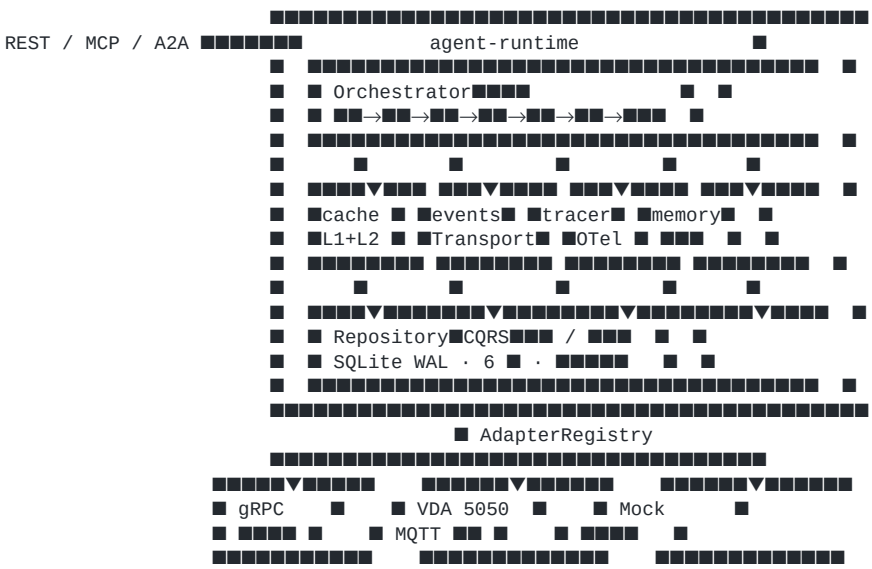

分层纪律：`tiangong_core` 不依赖任何基础设施（纯函数 + 不可变模型）；
基础设施（仓储/缓存/事件/追踪/适配器）只在 `app` 层装配，可整体替换（宪法第九条）。

---

4. 领域模型（核心对象）

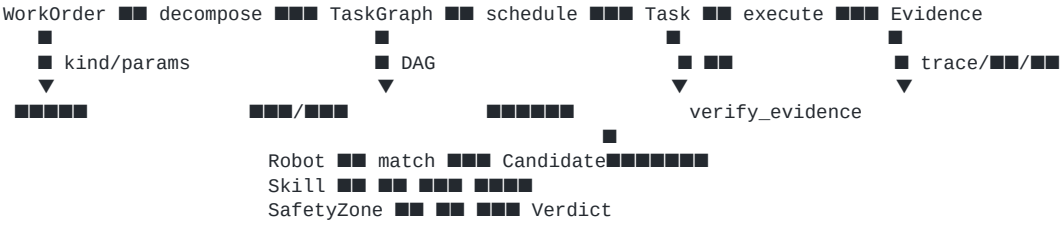

关键不变量：

- `TaskGraph` 必须无环（构造时 Kahn 校验）

- 任务状态只能沿白名单迁移（`lifecycle.py`）
- `Evidence` 只追加不修改（`replace` 语义）
- 技能只能引用 APPROVED 版本

---

5. 运行时基础设施（v1.1 新增）

v1.0 的架构分层干净但缺少工程化支撑（无缓存、无读写分离、无事件、无链路追踪），与 Diting-PdM 已具备的能力相比是退步。v1.1 按 docs/43 §4 补齐五项，全部在 `app` 层装配、核心包零改动（守住宪法第九条）。

5.1 CQRS 读写分离（`app/repository.py`）

项	设计
写侧	主连接，串行写事务；WAL 模式下不阻塞读
读侧	从连接（只读），承担看板/查询/统计
一致性	写后强一致场景（审批后立即执行）强制走主连接
表	`work_orders` / `tasks` / `episodes` / `skills` / `audit_log` / `zones`
迁移	内建 `CREATE TABLE IF NOT EXISTS`，零外部依赖；生产可平滑换 PostgreSQL
测试隔离	`file:tiangong_<uuid>?mode=memory&cache=shared`（多连接共享内存库）

> CQRS 在本项目的首要价值不是性能，而是语义清晰：写模型承载状态机与不变量，读模型服务看板与审计，两者演进解耦。

5.2 多级缓存（`app/cache.py`）

- L1：进程内 TTL 字典（默认短 TTL，按数据热度分层）
- L2：可插拔接口（Redis 预留）；L2 故障自动降级为仅 L1，不影响功能
- 失效：支持前缀批量失效（技能审批/安全区变更时使用）
- 观测：`hits / misses / hit_rate` 暴露于 `/observability/metrics`
- 纪律：缓存只缓存读模型，绝不缓存红线判定与令牌（安全判定必须实时）

5.3 事件总线（`app/events.py`）

- `Event`（frozen dataclass）+ `Transport` Protocol + `MemoryTransport`（生产换 Pulsar/Redis）
- 事件类型覆盖：作业单提交/审批/任务状态迁移/降级/停机/技能变更/证据落库
- 投递失败不阻塞主链路（降级纪律）：事件可重放，业务不可重放
- `GET /events` 暴露统计与最近 20 条，供值班排障

5.4 可观测（`app/otel.py`）

对齐 OTel GenAI Semantic Conventions，三层结构 Session > Trace > Span：

层	含义	本项目取值
Session	一次人机协作会话	作业单生命周期

层	含义	本项目取值
Trace	一次编排闭环	`trace_id`（贯穿分解→执行→证据）
Span	单个动作	`plan.*` / `safety.*` / `skill.*` / `evidence.*`

语义属性：`gen_ai.system`、`gen_ai.request.model`、`gen_ai.usage.input_tokens`、`gen_ai.usage.output_tokens`、`gen_ai.response.finish_reasons`。 无 OTel SDK 硬依赖（可零成本接入现有 APM），导出端点 `/observability/spans`。

5.5 多品牌适配（`app/robots/vda5050.py` + `AdapterRegistry`）

能力	说明
VDA 5050	MQTT 主题规范、`order`/`instantAction` 构造、`state` 解析、dry-run outbox
私有协议	实现同一 `RobotLink` 协议即可接入（gRPC 骨架见 `contracts/proto`）
注册表	按品牌注册/工厂创建/健康探测，`GET /adapters/health` 统一暴露
混场纪律	适配器只做协议翻译，不做业务决策；调度与安全判定在核心层统一

5.6 智能体互联（`app/a2a.py`）

- `GET /a2a/v1/card`：Agent Card（能力声明）
- `POST /a2a/v1/tasks`：意图委派入口（如 Diting-PdM 的设备异常 → 天工巡检作业单）
- 委派只传意图与参数，不传执行权限；落地仍需走本平台的审批与红线

---

6. 关键架构决策（ADR 索引）

#	决策	理由	详址
A1	软硬分层、契约先行	本体过剩、软件稀缺；协议差异关 adapter	contracts/proto
A2	大脑/小脑/脊髓三层	安全不依赖 LLM 可用性	§ 2
A3	规则规划器为默认兜底	可解释、可单测、LLM 挂了能跑	docs/05
A4	证据链作为完成判据	无证据不 DONE（可审计）	FR-502
A5	技能四态 + 灰度 + 回滚	受控资产（宪法第十条）	FR-601 – 603
A6	episode 强制 consent_id	数据合规（不出厂区）	FR-702
A7	SQLite 优先（演示）/ PostgreSQL（生产）	与 Diting-PdM 双后端同构	docs/09
A8	单基地双副本起步	可用性目标 99.5%	NFR-107
A9	CQRS 读写分离（写主/读从）	语义清晰优先，性能次之；为 PostgreSQL 铺路	§ 5.1

#	决策	理由	详址
A10	多级缓存只缓存读模型	红线与令牌必须实时，缓存会引入安全风险	§ 5.2
A11	事件总线不阻塞主链路	事件可重放、业务不可重放	§ 5.3
A12	自研轻量 tracer 对齐 OTel SemConv	避免 SDK 强绑定；可零成本接入现有 APM	§ 5.4
A13	适配器只翻译协议	业务决策统一在核心层，防止混场语义漂移	§ 5.5

---

7. 部署视图

- 演示/CI：单进程 Litestar + MockRobotDriver（无硬件），`TIANGONG_DB` 默认内存库
- 基地边缘：K3s 双副本 agent-runtime + 本地 SQLite（`TIANGONG_DB=/data/tiangong.db`，WAL）+ 本地 episode 缓存（弱网可断点续传）
- 总部中心：汇聚各基地脱敏 episode + 技能注册中心 + 看板

（清单见 `impl/deploy/k8s/`，多基地拓扑详 docs/09 § 4，运维细则详 docs/38）

---

8. 质量属性场景

属性	场景	响应
可用性	LLM 规划器超时	降级规则规划器（FR-105）
可用性	机器人执行失败	降级阶梯 L1→L4（FR-504）
可用性	L2 缓存不可用	自动退化为仅 L1，功能不受影响（§ 5.2）
安全性	停止区有人	毫秒级停机（FR-403）
安全性	缓存与安全判定冲突	红线/令牌不进缓存，永远实时（A10）
可审计	事故复盘	trace_id 重建全链 + 审计日志（FR-503）
可修改性	换机器人厂商	新 adapter，核心不动（A1/A13）
可扩展	新增品牌混场	注册表加一条 + 健康探测（§ 5.5）
性能	高峰 20 作业单并发	读走缓存与从库，目标 NFR-101/102
性能	看板高频查询	多级缓存 + 读连接，不打写侧