04 · 数据与技能架构

项	内容
文档 ID	TG-DOC-04
版本	v1.0
编制日期	2026-10-25
依据	数据飞轮方法论 / 技能治理 / 数据合规
状态	待评审

---

1. 数据总览：两类资产

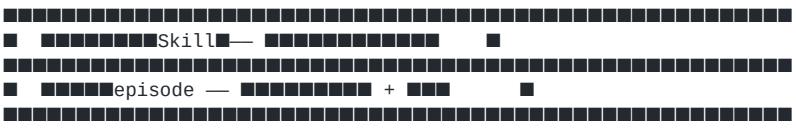

2026 = 具身智能"数据元年"：实景任务数据是训练场与模型厂商的采购对象。
本项目把每次真实作业变成带授权的训练数据，形成数据飞轮。

---

2. 技能数据模型

```
Skill (skill_id, name, description)
  ■■■ SkillVersion (skill_id, version, state, entry, canary_pct, approved_by)
        state ∈ {PENDING, APPROVED, REJECTED, SUPERSEDED}
```

规则：

- 新版本初始 PENDING，必须审批
- 同技能同时最多一个 APPROVED（生效版本 = version 最大者）
- 新版本获批 → 旧生效版本自动 SUPERSEDED
- 回滚 = 指定版本重新 APPROVED（不得回滚到 REJECTED）
- 执行引用的技能版本必须写入证据链

---

3. episode 数据模型

```
Episode(
  episode_id, task_id, robot_id,
  skill_id, skill_version, model_version,
  success, duration_s,
  observations: [...],   # ■■■■■■■■■
  actions: [...],        # ■■■■■
  outcome: {...},        # ■■
  consent_id             # ■■■■■■■■■■
)
```

- `checksum`：SHA-256 前 16 位，防篡改校验
- `shard_key`：`{skill_id}/{'ok'|'fail'}`，按场景聚合
- 导出：JSONL，供训练场/数据服务消费

3.1 合规红线

规则	实现
无授权单不入库	`EpisodeRecorder.record` 强制 consent_id
厂内数据不出厂	L3/L4 级数据（原始视频/波形）留基地，仅脱敏特征值上行
脱敏	采集前剥离人脸/工牌/商业秘密字段（adapter 层钩子）
可审计	checksum + consent_id + 版本号三元组

---

4. 数据流（飞轮）

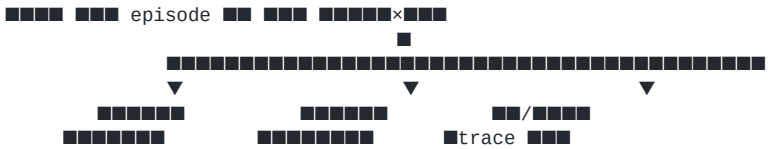

指标：

- 每技能成功率（`success_rate`）→ 低于阈值触发技能迭代或降级权重
- episode 总量与分片分布 → 数据资产盘点
- 人工接管率（L3 触发频次）→ 自动化成熟度

---

5. 存储选型

环境	选型	理由
演示/CI	SQLite + 内存	零依赖，全链路可跑
生产（基地）	PostgreSQL + 对象存储	与 Diting-PdM 双后端同构；episode 落对象存储
生产（总部）	数据湖（Parquet on S3）	分片导出直接可用

---

6. 与 Diting-PdM 数据体系的关系

Diting-PdM	天工	联动
设备健康指数 HI / 告警	作业单触发器	"HI 劣化 → 自动生成巡检作业单"
工单/备件	作业结果回写	"机器人完成 → 工单闭环"
判据版本化	技能版本化	同一治理哲学

合体愿景：谛听负责"该修了"，天工负责"去修/去查"——预测性维护 × 具身执行的全闭环。