09 · DevOps 交付流水线

项	内容
文档 ID	TG-DOC-09
版本	v1.1（新增持久化/可观测/多品牌适配的部署口径）
编制日期	2026-10-26（首版 2026-10-25）
依据	CI/CD 门禁统一
状态	已评审

---

1. 流水线总览

```
push/PR ■■■ CI■.github/workflows/ci.yml■
              ■■ lint■ruff■
              ■■ test■pytest --maxfail=1■
              ■■ coverage■--fail-under=80■
              ■■ demo smoke■■■■■■■■■
              ■■ buf lint■■■■
                    ■
                    ▼ ■■
              build ■■ ■■■ ■■■K3s / K8s■
```

统一门禁原则：语言可不同，门槛必须一致（与 Diting-PdM 同）。

---

2. 本地开发流

```
make test       # ■■■■
make coverage   # ■■■
make lint       # ruff
make demo       # ■■■■
make run        # ■■■ :8000
make smoke      # ■■■healthz + robots■
```

---

3. 制品与镜像

- 镜像：`registry/tiangong/agent-runtime:<version>`
- 版本：语义化（0.1.0 起）；每次发版对应 git tag
- 安全基线：`readOnlyRootFilesystem` + `runAsNonRoot` + 资源限额（见 deploy/k8s）

3.1 运行时配置（必配项）

变量 / 挂载	生产值	说明
`TIANGONG_DB`	`/data/tiangong.db`	不设则为内存库，重启即丢
`TIANGONG_BULK_DB`	`/data/tiangong_bulk.db`	分析库（1 亿条事实 + 预聚合）；不设为"分析不可用"，接口降级
`TIANGONG_REDIS_URL`	`redis://redis:6379/0`	L2 缓存；不设则只用 L1（功能不受影响）
`TIANGONG_CACHE_TTL`	`5`	L1 默认 TTL（秒）
`/data` 卷	PVC（≥ 20 GiB，含分析库建议 ≥ 60 GiB）	SQLite + WAL + 分析库
`/episodes` 卷	对象存储或 PVC	episode 分片，按天分片

变量 / 挂载	生产值	说明
`TZ`	`Asia/Shanghai`	审计时间口径统一

> 分析库与预聚合的部署纪律：1. 分析库随镜像/数据包分发或用 `tools/gen_bulk_data.py` + `tools/build_rollup.py` 离线构建；2. 预聚合必须与明细同批更新（否则口径漂移）：每日 ETL 末尾执行 `build_rollup.py --rebuild`；3. 服务重启前执行 `tools/warmup_cache.py`，冷启动首请求即可命中 L2（docs/44 §5）。

> 单副本写库限制：SQLite 为单写者模型，agent-runtime 写实例应为 1；
> 需要横向扩展时，读实例可多副本（走读连接 + 缓存），写实例保持单点并由 K8s 保证重启。 这是 A7 决策的显式代价，生产规模化时按 A9 迁移 PostgreSQL（届时可多写）。

---

4. 部署拓扑

4.1 单基地（演示/首期）

```
K3s ■■
■■■ agent-runtime (×2 ■■)
■■■ PostgreSQL■■■/■■/episode ■■■■
■■■ ■■■■■episode ■■■
```

4.2 多基地（Ph3）

```
■■■■
■■■ ■■■■■■■■■■/■■/■■■■■■■■■■
■■■ ■■■■■■■ episode ■■■
■■■ ■■■■■■■/■■■/■■■■■■■

■■■■■■■■■■
■■■ agent-runtime■■■■■■■■■■■■■■
■■■ ■■ episode ■■■■■■■■■
■■■ RobotLink adapters
```

> 边缘自治原则：网络中断不影响已审批作业单的本地执行； 恢复后 episode 与审批记录自动同步。

4.3 多品牌接入拓扑（v1.1）

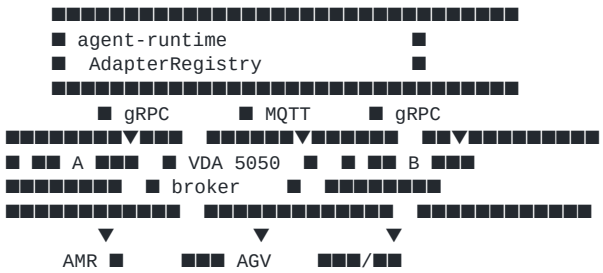

- 适配器以独立 Deployment 或 sidecar 部署，崩溃不拖垮编排主进程
- broker 与网关需在安全区网络内，禁止跨区直连（等保边界）
- 新增品牌 = 新增 adapter + 注册表登记，不改核心与服务逻辑

---

5. 观测

5.1 指标口径

层	指标	采集端点
业务	作业单完成率 / 平均节拍 / 人工接管率	`/tg-api/v1/episodes/stats`

层	指标	采集端点
技能	每技能成功率 / 降级触发分布	`episodes/stats.success_rate` + RunReport
安全	红线违规次数 / 停机次数 / 急停次数	`/tg-api/v1/audit`
系统	API P95 / span 错误率 / 缓存命中率	`/tg-api/v1/observability/metrics`
链路	单次作业全链 span	`/tg-api/v1/observability/spans?trace_id=`
集成	事件投递与失败数	`/tg-api/v1/events`
适配	各品牌健康与延迟	`/tg-api/v1/adapters/health`

5.2 与外部 APM 对接

`app/otel.py` 输出的 span 结构对齐 OTel GenAI SemConv（`gen_ai.system`、`gen_ai.request.model`、`gen_ai.usage.*`），可直接映射到现有 APM 的 LLM 观测面板；未引入 OTel SDK 是刻意选择（避免版本绑定），接入时只需在 `Tracer` 内加一个 exporter。

5.3 告警建议阈值

见 docs/38 §5.1（含分级、首响时限与升级路径），DevOps 侧只负责规则落地与通知通道。

5.4 性能基线（实测，1 亿条数据）

场景	实测	阈值	数据来源
全链路 P95（读为主）	1.53 ms	< 300 ms	k6 16,823 请求
下单→审批→执行 P95	7 ms	< 1200 ms	k6 write_chain
聚合查询 P95（缓存命中）	1 ms	< 120 ms	k6 an_summary
聚合查询（预聚合，无缓存）	0.23 – 1.06 ms	—	docs/44 §4.3
缓存命中率	99.96%	> 60%	压测期
失败率	0.00%	< 1%	k6 + Locust

> 容量结论：单进程 granian + 预聚合 + 两级缓存在本机可稳定承载 250+ rps（读为主）。写路径受 SQLite 单写者限制，规模化前需按 A9 迁移 PostgreSQL。回归方式：`make perf-k6` / `make perf-locust`（脚本内置阈值，不达标即退出非 0）。

---

6. 回滚策略

对象	回滚方式	RTO
服务	镜像版本回滚	< 5 min
技能	`POST /skills/{id}/rollback?to={v}`	即时
计划	任务 SUPERSEDED + 重新分解	即时
数据	episode checksum 校验 + 分片重导	< 1 h

---

7. 环境管理

环境	用途	数据
dev	开发联调	合成
staging	验收（42 项检查单）	脱敏实景
prod	生产	受控

晋升规则：dev → staging 自动；staging → prod 需安全签字（docs/11）。